

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



Nhập môn AI

Báo cáo Bài Tập Lớn

Hệ thống Hybrid cho Xe tự hành

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân

Sinh viên thực hiện: Nguyễn Đăng Khoa - 2352570
Nguyễn Trần Gia Bảo - 2352103
Nguyễn Việt Hưng - 2352442
Lê Duy Nhật Minh - 2352740

THÀNH PHỐ HỒ CHÍ MINH, 2026

Mục lục

1	Tổng quan dự án	3
1.1	Thông tin nhóm	3
1.2	Bảng phân công công việc	3
1.3	Mã nguồn và tài nguyên đính kèm	3
2	Giới thiệu đề tài	4
2.1	Mục tiêu đề tài	4
2.2	Giới hạn phạm vi đề tài	5
3	EDA - Phân tích tập dữ liệu	6
3.1	Tổng quan tập dữ liệu	6
3.2	Cấu trúc dữ liệu	7
3.2.1	Nhóm thông tin môi trường giao thông	7
3.2.2	Nhóm thông tin hình học đường	8
3.2.3	Nhóm thông tin động học phương tiện	8
3.2.4	Nhóm điều kiện môi trường	8
3.2.5	Nhãn hành vi đầu ra	8
3.3	Tiền xử lý dữ liệu	9
4	Mô hình hóa bài toán AI	9
4.1	State – Mô hình trạng thái môi trường	10
4.2	Action – Mô hình hành động điều hướng	10
4.3	Goal – Mô hình trạng thái mục tiêu động	11
4.4	Cost Map Fusion	11
4.4.1	Tổng quan luồng xử lý	13
4.5	Uncertainty Modeling - Mô hình xác suất rủi ro Bayesian	13
4.5.1	Xây dựng xác suất rủi ro nền	13
4.5.2	Biểu diễn xác suất dưới dạng Odds	13
4.5.3	Likelihood Ratio từ Machine Learning	14
4.5.4	Cập nhật Bayesian động	14
4.6	Knowledge Representation - Mô hình hệ luật và ràng buộc an toàn	14
4.7	Learning Mechanism – Xử lý Feature cho mô hình Học Máy	15
4.7.1	Nhóm đặc trưng vận tốc và va chạm	15
4.7.2	Nhóm đặc trưng vận hành phương tiện	16
4.7.3	Nhóm đặc trưng hình học và quỹ đạo	16
4.7.4	Nhóm đặc trưng môi trường và giao thông	17
4.7.5	Nhóm đặc trưng nguy hiểm động học	17
4.7.6	Nhóm đặc trưng rủi ro tổng hợp	18



5	Các thuật toán sử dụng	18
5.1	Tiền xử lý dữ liệu	19
5.2	Behavior Prediction – Dự đoán hành vi	19
5.2.1	Gaussian Naive Bayes	19
5.2.2	Random Forest Classifier	20
5.2.3	XGBoost Classification	20
5.3	Risk Probability Prediction – Dự đoán xác suất rủi ro	20
5.3.1	Decision Tree Regressor	21
5.3.2	XGBoost Regression	21
5.4	Path Planning - Mô hình tìm kiếm quỹ đạo	21
5.5	Cơ chế lựa chọn mô hình	22
6	Thực nghiệm	22
6.1	Đánh giá mô hình Behavior Prediction	23
6.2	Đánh giá mô hình Risk Prediction	23
6.3	Hiệu suất thuật toán A*	24
6.4	Đánh giá an toàn và ổn định hệ thống	24
7	Phân tích kết quả	25
8	Kết luận	26

1 Tổng quan dự án

1.1 Thông tin nhóm

Đơn vị thực hiện:

- Trường Đại học Bách Khoa TP.HCM (HCMUT)

1.2 Bảng phân công công việc

Thành viên	Nhiệm vụ thực hiện	Tiến độ
Nguyễn Đăng Khoa (2352570)	• Thiết kế kiến trúc hybrid NeuroDrive-K. • Triển khai module Path Planning. • Xây dựng Heuristic Function và A* Fallback. • Huấn luyện và tuning các mô hình Machine Learning. • Hỗ trợ viết báo cáo hệ thống.	100%
Nguyễn Trần Gia Bảo (2352103)	• Tiền xử lý dữ liệu. • Visualization kết quả thực nghiệm. • Thiết lập Cost Map cho môi trường điều hướng. • Xây dựng Soft Rules cho Rule-based Safety System.	100%
Nguyễn Việt Hưng (2352442)	• Xây dựng Hard Rules cho Rule-based Safety System. • Hỗ trợ viết báo cáo hệ thống.	100%
Lê Duy Nhật Minh (2352740)	• Thiết kế bộ lọc xác suất khử nhiễu Bayesian Probability Network. • Hỗ trợ viết báo cáo hệ thống.	100%

Bảng 1: Bảng phân công công việc của các thành viên trong nhóm

1.3 Mã nguồn và tài nguyên đính kèm

- [GitHub Repository – NeuroDrive-K](#)
- [Google Colab Notebook](#)
- [Dataset mô phỏng](#)

2 Giới thiệu đề tài

Trong bối cảnh công nghệ AI và cuộc cách mạng công nghiệp 4.0 phát triển mạnh mẽ, xe tự hành đang trở thành lĩnh vực nghiên cứu quan trọng nhờ khả năng nâng cao an toàn giao thông, giảm tai nạn và hỗ trợ xây dựng đô thị thông minh.

Tuy nhiên, hệ thống xe tự hành phải đối mặt với nhiều thách thức như dữ liệu cảm biến nhiễu, thời tiết bất lợi, môi trường giao thông phức tạp và yêu cầu ra quyết định thời gian thực với độ chính xác cao.

Từ đó, đề tài **NeuroDrive-K** được xây dựng nhằm phát triển một framework Hybrid AI cho xe tự hành, kết hợp:

- **Machine Learning** để nhận diện và phân tích môi trường,
- **Bayesian Probability** để xử lý dữ liệu không chắc chắn và dự đoán rủi ro,
- **Rule-based System** để đảm bảo tuân thủ an toàn giao thông,
- **Heuristic Search (A*)** để tạo ra quỹ đạo di chuyển tối ưu nhất.

Hệ thống hướng đến khả năng nhận thức môi trường chính xác, phát hiện nguy hiểm sớm, điều hướng an toàn và thích nghi tốt với các tình huống giao thông thực tế. Đề tài đồng thời có tiềm năng ứng dụng trong các hệ thống giao thông thông minh và phương tiện tự hành thế hệ mới.

2.1 Mục tiêu đề tài

Đề tài xây dựng framework hybrid AI **NeuroDrive-K** cho xe tự hành thông minh với các chức năng chính:


- **Nhận thức môi trường:** xử lý dữ liệu giao thông như khoảng cách vật cản, tốc độ, mật độ xe, làn đường và thời tiết.
- **Đánh giá rủi ro:** sử dụng Machine Learning và Bayesian Probability để phát hiện nguy hiểm, suy luận xác suất va chạm và xử lý dữ liệu không chắc chắn.
- **Đảm bảo an toàn:** áp dụng hệ luật IF-THEN nhằm tuân thủ luật giao thông và ưu tiên an toàn trong mọi tình huống.
- **Điều hướng thông minh:** sử dụng thuật toán A* để tìm quỹ đạo tối ưu và hỗ trợ ra quyết định thời gian thực.

Đầu ra của hệ thống gồm quỹ đạo di chuyển tối ưu và các hành động như *phanh khẩn cấp, giữ làn, chuyển làn hoặc vượt xe an toàn*. Framework cũng được thiết kế mở để dễ dàng mở rộng với Deep Learning, Reinforcement Learning và V2X trong tương lai.

2.2 Giới hạn phạm vi đề tài

Đề tài tập trung vào tăng **suy luận và lập kế hoạch điều hướng** cho xe tự hành, thay vì xử lý dữ liệu cảm biến mức thấp như camera, LiDAR hay radar.

Hệ thống giả định dữ liệu đầu vào đã được tiền xử lý và chuyển thành vector đặc trưng phục vụ cho AI. Vì vậy, trọng tâm nghiên cứu là pipeline Hybrid AI:




Trong đó:

- **Perception:** mô hình hóa môi trường giao thông,
- **Machine Learning Train:** huấn luyện các mô hình học máy để dự đoán hành vi giao thông và đánh giá mức độ rủi ro,
- **Bayesian Update:** cập nhật xác suất rủi ro,
- **Knowledge Constraints:** áp dụng luật giao thông và các ràng buộc an toàn,
- **Cost Map Fusion:** kết hợp thông tin rủi ro, vật cản và điều kiện mặt đường để xây dựng bản đồ lưới chi phí,
- **A* Search Planning:** tối ưu quỹ đạo điều hướng.

3 EDA - Phân tích tập dữ liệu

3.1 Tổng quan tập dữ liệu



Hình 1: Biểu đồ phân tích mức độ quan trọng của các đặc trưng bằng SHAP

Đề tài sử dụng tập dữ liệu mô phỏng **Autonomous Driving Sensor-Kinematics Dataset**, bao gồm thông tin cảm biến môi trường, trạng thái động học xe, điều kiện giao thông, thời tiết và nhân hành vi điều hướng.

Mỗi mẫu dữ liệu đại diện cho một trạng thái giao thông tại một thời điểm, phục vụ cho các nhiệm vụ nhận thức tình huống, đánh giá rủi ro và lập kế hoạch điều hướng.

3.2 Cấu trúc dữ liệu



Hình 2: Biểu đồ phân tích dữ liệu

Tập dữ liệu bao gồm nhiều thuộc tính đầu vào (features) và một nhãn đầu ra (behavior label). Các thuộc tính này được chia thành các nhóm chính như sau:

3.2.1 Nhóm thông tin môi trường giao thông

- **obstacle_distance_m**: Khoảng cách tới vật cản gần nhất (mét).
- **relative_speed_mps**: Chênh lệch tốc độ giữa xe tự hành và phương tiện phía trước (m/s).
- **num_obstacles**: Số lượng vật cản xuất hiện trong vùng quan sát.
- **traffic_density_veh_per_km**: Mật độ phương tiện giao thông trên mỗi km đường.
- **risk_probability**: Xác suất rủi ro được ước lượng từ môi trường giao thông.

Nhóm thuộc tính này đóng vai trò mô tả mức độ nguy hiểm và độ phức tạp của môi trường giao thông mà hệ thống đang xử lý.

3.2.2 Nhóm thông tin hình học đường

- **lane_offset_m**: Độ lệch của xe so với tâm làn đường.
- **road_curvature_1pm**: Độ cong của mặt đường.
- **road_width_m**: Chiều rộng mặt đường.
- **speed_limit_kmh**: Giới hạn tốc độ của tuyến đường.

Các thuộc tính này giúp hệ thống đánh giá cấu trúc đường đi và hỗ trợ quá trình lập kế hoạch quỹ đạo an toàn.

3.2.3 Nhóm thông tin động học phương tiện

- **ego_speed_mps**: Tốc độ hiện tại của xe tự hành.
- **ego_acceleration_mps2**: Gia tốc của xe.
- **steering_angle_deg**: Góc đánh lái của vô lăng.
- **yaw_rate_rads**: Tốc độ quay quanh trục đứng của xe.
- **throttle_position**: Mức độ nhấn chân ga.
- **brake_pressure**: Áp lực phanh hiện tại.

Nhóm dữ liệu này phản ánh trạng thái vận hành động học của xe trong từng thời điểm.

3.2.4 Nhóm điều kiện môi trường

- **weather_condition**: Điều kiện thời tiết gồm *clear*, *rain*, *fog*, *night*.
- **visibility_range_m**: Phạm vi quan sát của cảm biến.
- **road_surface_condition**: Trạng thái mặt đường gồm *dry*, *wet*, *icy*.

Các yếu tố môi trường này có ảnh hưởng trực tiếp tới khả năng nhận thức và độ an toàn của xe tự hành.

3.2.5 Nhãn hành vi đầu ra

Thuộc tính **behavior_label** đại diện cho quyết định chiến thuật mà hệ thống cần thực hiện trong tình huống tương ứng. Các nhãn hành vi bao gồm:

- **follow**: Theo xe phía trước.
- **stop**: Dừng xe.
- **yield**: Nhường đường.

- **lane_change**: Chuyển làn.
- **overtake**: Vượt xe.

Đây là nhân mục tiêu chính được sử dụng trong quá trình huấn luyện mô hình Machine Learning.

3.3 Tiền xử lý dữ liệu

Trước khi đưa vào huấn luyện mô hình AI, dữ liệu cần được tiền xử lý nhằm đảm bảo tính ổn định và hiệu quả của hệ thống.

Các bước tiền xử lý bao gồm:

- Chuẩn hóa dữ liệu số liên tục.
- Mã hóa dữ liệu dạng phân loại (categorical encoding).
- Kiểm tra và xử lý dữ liệu thiếu (missing value).
- Phát hiện và xử lý dữ liệu ngoại lai (outlier detection).
- Tách dữ liệu thành tập huấn luyện và tập kiểm thử.

Đối với các thuộc tính dạng chuỗi như:

- weather_condition,
- road_surface_condition,
- behavior_label,

Hệ thống sử dụng kỹ thuật mã hóa số để chuyển đổi sang dạng vector phù hợp cho các mô hình Machine Learning.

4 Mô hình hóa bài toán AI

Trong đề tài này, hệ thống xe tự hành được mô hình hóa theo luồng xử lý tuần tự gồm bốn thành phần chính:

$$State \rightarrow Action \rightarrow Goal \rightarrow Cost$$

Mỗi thành phần đại diện cho một giai đoạn trong quá trình ra quyết định của hệ thống Hybrid AI.

4.1 State – Mô hình trạng thái môi trường

Tại thời điểm t , hệ thống tiếp nhận thông tin môi trường giao thông và biểu diễn dưới dạng vector trạng thái:

$$S_t = \{x_1, x_2, x_3, \dots, x_n\}$$

Trong đó, mỗi biến x_i là một đặc trưng phản ánh trạng thái hiện tại của môi trường hoặc xe tự hành. Do môi trường giao thông luôn thay đổi theo thời gian thực, trạng thái S_t liên tục được cập nhật từ dữ liệu cảm biến và mô phỏng môi trường.

Không gian trạng thái tổng quát của hệ thống được mô hình hóa như sau:

$$S = (Environment, Vehicle, Risk, Constraints)$$

Trong đó:

- *Environment*: thông tin môi trường giao thông,
- *Vehicle*: trạng thái động học của xe,
- *Risk*: mức độ rủi ro động,
- *Constraints*: các ràng buộc an toàn và luật giao thông.

Tập trạng thái S_t đóng vai trò là đầu vào cho toàn bộ hệ thống suy luận Hybrid AI.

4.2 Action – Mô hình hành động điều hướng

Dựa trên trạng thái môi trường S_t , hệ thống thực hiện suy luận để lựa chọn hành động điều hướng:

$$A_t \in \{follow, stop, yield, lane_change, overtake\}$$

Quá trình suy luận được mô hình hóa bằng hàm:

$$f : S_t \rightarrow A_t$$

Trong đó:

- S_t : trạng thái môi trường,
- A_t : hành động được lựa chọn,
- f : hàm suy luận của hệ thống Hybrid AI.

4.3 Goal – Mô hình trạng thái mục tiêu động

Sau khi xác định hành động A_t , hệ thống thiết lập trạng thái mục tiêu động:

$$G = (g_x, g_y)$$

Trạng thái đích được thay đổi tùy theo hành động điều hướng:

- **Follow / Yield:** đích nằm tại trung tâm làn đường hiện tại,
- **Lane Change / Overtake:** đích được dịch chuyển sang làn mục tiêu,
- **Stop:** đích trùng với vị trí hiện tại:

$$G = S_{start}$$

Việc xác định Goal động giúp hệ thống thích nghi với môi trường giao thông thay đổi liên tục trong thời gian thực.

4.4 Cost Map Fusion

NeuroDrive-K mô hình hóa môi trường giao thông dưới dạng một lưới 2D (Grid Environment) kích thước $grid_height \times grid_width$.

Mỗi ô trên lưới biểu diễn một trạng thái không gian cục bộ mà xe có thể đi qua, trong đó giá trị của ô tương ứng với mức chi phí di chuyển (cost value) tại vị trí đó.

- Trục x biểu diễn hướng chuyển động tiến về phía trước.
- Trục y biểu diễn vị trí ngang theo làn đường.
- Các ô gần tim đường có chi phí thấp hơn.
- Các ô gần vật cản hoặc vùng nguy hiểm có chi phí cao hơn.
- Các ô vi phạm luật hoặc va chạm được gán giá trị INF .

Sau khi xác định trạng thái mục tiêu G_t , hệ thống sử dụng thuật toán A^* để tìm quỹ đạo tối ưu:

$$\tau^* = \arg \min_{\tau} J(\tau)$$

Trong đó, hàm chi phí tổng quát được định nghĩa:

$$J(\tau) = \sum_{(x,y) \in \tau} (w_1 C_{dist} + w_2 C_{risk} + w_3 C_{lane} + C_{rule})$$

với:

- C_{dist} : chi phí khoảng cách tới mục tiêu,
- C_{risk} : chi phí rủi ro vật cản,
- C_{lane} : chi phí lệch làn,
- C_{rule} : chi phí vi phạm luật hoặc va chạm,
- w_1, w_2, w_3 : trọng số ưu tiên.

Chi phí khoảng cách

$$C_{dist} = \sqrt{(x - g_x)^2 + (y - g_y)^2}$$

Giúp xe tiến dần tới trạng thái mục tiêu với quãng đường tối ưu.

Chi phí rủi ro

$$C_{risk} = \exp\left(-\frac{(x - x_o)^2 + (y - y_o)^2}{2\sigma^2}\right)$$

Mô hình hóa vùng nguy hiểm xung quanh vật cản bằng phân phối Gaussian nhằm giảm khả năng va chạm.

Chi phí lệch làn

$$C_{lane} = |x - x_{lane}|$$

Khuyến khích xe duy trì quỹ đạo ổn định quanh tâm làn đường.

Chi phí quy tắc

$$C_{rule} = \begin{cases} \infty, & \text{nếu vi phạm luật hoặc va chạm} \\ 0, & \text{ngược lại} \end{cases}$$

Áp dụng cho các vùng như:

- Biên đường,
- Dải phân cách,
- Vùng cấm,
- Khoảng cách an toàn tối thiểu.

Từ các thành phần trên, hệ thống xây dựng *cost map* dùng làm đầu vào cho bộ lập kế hoạch quỹ đạo. Thuật toán A* sẽ tìm đường đi có tổng chi phí nhỏ nhất nhưng vẫn đảm bảo an toàn và tuân thủ luật giao thông.

4.4.1 Tổng quan luồng xử lý

Toàn bộ pipeline ra quyết định của hệ thống được mô hình hóa như sau:

$$S_t \xrightarrow{f} A_t \longrightarrow G \longrightarrow \arg \min_{\tau} J(\tau)$$

Trong đó:

- S_t : trạng thái môi trường hiện tại,
- A_t : hành động điều hướng được suy luận,
- G : trạng thái mục tiêu,
- $J(\tau)$: hàm chi phí cần tối ưu,
- τ : quỹ đạo tối ưu của xe tự hành.

4.5 Uncertainty Modeling - Mô hình xác suất rủi ro Bayesian

Trong NeuroDrive-K, Bayesian Probability được sử dụng để cập nhật mức độ rủi ro theo thời gian thực dựa trên điều kiện môi trường, trạng thái mặt đường, tầm nhìn cảm biến và kết quả dự đoán từ Machine Learning.

Mô-đun này giúp hệ thống xử lý dữ liệu bất định, kết hợp tri thức môi trường với AI và đánh giá nguy hiểm động trong quá trình vận hành.

4.5.1 Xây dựng xác suất rủi ro nền

Hệ thống trước tiên tính toán xác suất rủi ro nền (*Base Risk*) từ các yếu tố như thời tiết, trạng thái mặt đường và tầm nhìn cảm biến. Điều kiện bất lợi như mưa, sương mù, ban đêm hoặc mặt đường trơn trượt sẽ làm tăng mức độ nguy hiểm.

Xác suất rủi ro nền được mô hình hóa:

$$P_{base} = P_{weather} + P_{surface} + P_{visibility}$$

trong đó $P_{weather}$, $P_{surface}$ và $P_{visibility}$ lần lượt biểu diễn mức rủi ro do thời tiết, mặt đường và khả năng quan sát.

4.5.2 Biểu diễn xác suất dưới dạng Odds

Để cập nhật Bayesian hiệu quả hơn, hệ thống chuyển xác suất sang dạng *Odds Ratio*:

$$Odds = \frac{P}{1 - P}$$

Cách biểu diễn này giúp tăng độ ổn định số học và thuận tiện khi kết hợp với likelihood ratio. Sau khi cập nhật, odds được chuyển ngược về xác suất:

$$P = \frac{Odds}{1 + Odds}$$

4.5.3 Likelihood Ratio từ Machine Learning

NeuroDrive-K sử dụng đầu ra từ mô hình Machine Learning dưới dạng $RiskScore_{ML}$ để xây dựng *Likelihood Ratio*:

$$LR = e^{(RiskScore_{ML} - 0.5) \times \lambda}$$

trong đó LR là likelihood ratio và λ là hệ số khuếch đại ảnh hưởng của mô hình ML.

Cơ chế này cho phép hệ thống linh hoạt tăng hoặc giảm mức rủi ro tùy theo đánh giá nguy hiểm của AI.

4.5.4 Cập nhật Bayesian động

Sau khi có xác suất nền và likelihood ratio, hệ thống thực hiện Bayesian Update theo cơ chế log-odds:

$$Odds_{posterior} = Odds_{prior} \times LR$$

Từ đó, xác suất rủi ro cuối cùng được tính:

$$P_{dynamic} = \frac{Odds_{posterior}}{1 + Odds_{posterior}}$$

Giá trị này phản ánh đồng thời điều kiện môi trường, trạng thái giao thông và dự đoán từ Machine Learning.

4.6 Knowledge Representation - Mô hình hệ luật và ràng buộc an toàn

Hệ thống biểu diễn tri thức dưới dạng các luật điều hướng và ràng buộc an toàn. Tri thức được biểu diễn thông qua các luật IF-THEN nhằm mô phỏng các nguyên tắc vận hành của hệ thống giao thông thực tế, hạn chế hành động nguy hiểm và tăng khả năng giải thích của hệ thống AI:

1. Luật tránh va chạm khẩn cấp

IF $TTC < TTC_{critical}$ OR khoảng cách vật cản quá nhỏ THEN hành động *stop*

2. Luật an toàn tầm nhìn

IF visibility quá thấp THEN hành động *stop*

3. Luật điều chỉnh tốc độ

IF $EgoSpeed > SafeSpeed$ THEN hành động *yield*

4. Luật giao thông nguy hiểm

IF mật độ giao thông cao OR xác suất rủi ro Bayesian lớn THEN ưu tiên *yield*

5. Luật vượt xe an toàn

IF giao thông ổn định AND khoảng cách đủ lớn AND làn đường đủ rộng THEN hành động *overtake*

6. Luật chuyển làn

IF không thể vượt xe nhưng tồn tại làn di chuyển an toàn THEN hành động *lane_change*

7. Luật bám làn

IF trạng thái giao thông ổn định AND không tồn tại nguy cơ cao THEN hành động *follow*

8. Luật kiểm tra vi phạm an toàn

IF vượt tốc độ OR lệch làn nguy hiểm OR khoảng cách không an toàn THEN kích hoạt cảnh báo an toàn

9. Luật thiết lập mục tiêu điều hướng

IF hành vi *follow* THEN Goal State nằm gần tâm làn

IF hành vi *lane_change* THEN Goal State dịch chuyển sang làn kế bên

IF hành vi *overtake* THEN Goal State tạo quỹ đạo vượt rộng hơn

Nhóm luật IF–THEN này tạo thành lớp kiểm soát logic của NeuroDrive-K, giúp hệ thống duy trì tính an toàn, khả năng giải thích và độ ổn định trong quá trình ra quyết định điều hướng.

4.7 Learning Mechanism – Xử lý Feature cho mô hình Học Máy

NeuroDrive-K sử dụng Machine Learning trên tập dữ liệu đã qua Feature Engineering nhằm học các mẫu hành vi và đặc trưng nguy hiểm trong giao thông. Hệ thống xây dựng thêm các đặc trưng như thời gian va chạm dự đoán, nguy hiểm động học và độ khẩn cấp phanh để mô hình hiểu rõ bản chất tình huống giao thông thay vì chỉ học quan hệ thống kê. Nhờ đó, hệ thống có khả năng dự đoán rủi ro, hỗ trợ điều hướng và cải thiện lập kế hoạch quỹ đạo trong nhiều điều kiện vận hành khác nhau.

4.7.1 Nhóm đặc trưng vận tốc và va chạm

Nhóm đặc trưng này được xây dựng nhằm phản ánh nguy cơ va chạm dựa trên khoảng cách và tốc độ tương đối giữa các phương tiện.

Closing Rate: Closing Rate biểu diễn tốc độ tiếp cận giữa xe tự hành và vật cản phía trước. Giá trị càng lớn cho thấy nguy cơ va chạm càng cao.

$$Closing\ Rate = \max(Relative\ Speed, 0)$$

Time To Collision (TTC): TTC là thời gian ước lượng trước khi xảy ra va chạm nếu hai phương tiện tiếp tục di chuyển với vận tốc hiện tại.

$$TTC = \frac{Obstacle\ Distance}{Closing\ Rate}$$

Giá trị TTC nhỏ thể hiện tình huống nguy hiểm và yêu cầu phản ứng khẩn cấp.

Safety Ratio: Safety Ratio phản ánh mức độ an toàn dựa trên tỷ lệ giữa khoảng cách vật cản và vận tốc hiện tại của xe.

$$Safety\ Ratio = \frac{Obstacle\ Distance}{Ego\ Speed}$$

Giá trị thấp cho thấy xe đang di chuyển quá nhanh so với khoảng cách an toàn.

4.7.2 Nhóm đặc trưng vận hành phương tiện

Nhóm đặc trưng này mô tả trạng thái vận hành động học của xe tự hành.

Ego Speed in km/h: Tốc độ xe được chuyển đổi sang đơn vị km/h nhằm đồng nhất với giới hạn tốc độ giao thông.

$$Speed_{km/h} = Speed_{m/s} \times 3.6$$

Speed Over Limit: Đặc trưng này phản ánh mức độ vượt quá giới hạn tốc độ cho phép.

$$Speed\ Over\ Limit = Ego\ Speed - Speed\ Limit$$

Giá trị dương cho thấy phương tiện đang vượt tốc độ quy định.

Brake-Throttle Difference: Đặc trưng này mô tả sự chênh lệch giữa thao tác phanh và chân ga.

$$BrakeThrottleDiff = Brake\ Pressure - Throttle\ Position$$

Giá trị lớn thể hiện xu hướng giảm tốc mạnh.

4.7.3 Nhóm đặc trưng hình học và quỹ đạo

Nhóm đặc trưng này phản ánh độ ổn định của xe khi di chuyển trên đường cong hoặc lệch làn.

Curvature Magnitude: Đặc trưng này biểu diễn độ cong tuyệt đối của mặt đường.

$$CurvatureAbs = |Road\ Curvature|$$

Centrifugal Risk: Centrifugal Risk mô hình hóa nguy cơ mất ổn định khi xe di chuyển tốc độ cao trên đường cong.

$$Centrifugal\ Risk = CurvatureAbs \times Speed^2$$

Giá trị lớn cho thấy nguy cơ mất lái hoặc trượt bánh tăng cao.

Lane Danger: Lane Danger phản ánh mức độ nguy hiểm khi xe lệch khỏi tâm làn đường ở tốc độ cao.

$$Lane\ Danger = |Lane\ Offset| \times Ego\ Speed$$

4.7.4 Nhóm đặc trưng môi trường và giao thông

Nhóm đặc trưng này mô tả ảnh hưởng của môi trường giao thông tới độ an toàn vận hành.

Visibility Factor: Visibility Factor biểu diễn chất lượng quan sát của hệ thống cảm biến.

$$Visibility\ Factor = \frac{Visibility\ Range}{500}$$

Giá trị nhỏ cho thấy tầm nhìn bị hạn chế.

Weather-Visibility Interaction: Đặc trưng này mô hình hóa tác động kết hợp giữa thời tiết và khả năng quan sát.

$$WeatherVisibility = WeatherEncoded \times \left(1 - \frac{Visibility\ Range}{500}\right)$$

Giá trị lớn thể hiện điều kiện môi trường nguy hiểm.

Congestion Index: Congestion Index phản ánh mức độ ùn tắc giao thông dựa trên mật độ phương tiện và số lượng vật cản.

$$Congestion\ Index = Traffic\ Density \times NumObstacles$$

4.7.5 Nhóm đặc trưng nguy hiểm động học

Nhóm đặc trưng này được xây dựng nhằm đánh giá mức độ nguy hiểm vật lý trong quá trình vận hành.

Kinetic Danger: Đặc trưng này biểu diễn mức độ nguy hiểm động năng của phương tiện trong môi trường giao thông đông đúc.

$$Kinetic\ Danger = Ego\ Speed \times Traffic\ Density$$

Braking Urgency: Braking Urgency phản ánh mức độ cần thiết phải phanh khẩn cấp.

$$Braking\ Urgency = \frac{(\Delta v)^2}{2 \times ObstacleDistance}$$

Trong đó:

$$\Delta v = EgoSpeed - RelativeSpeed$$

Giá trị lớn cho thấy nguy cơ va chạm cao nếu không giảm tốc kịp thời.

Deceleration Needed: Đặc trưng này biểu diễn gia tốc âm cần thiết để tránh va chạm.

$$Deceleration\ Needed = \frac{RelativeSpeed^2}{2 \times ObstacleDistance}$$

4.7.6 Nhóm đặc trưng rủi ro tổng hợp

Để xây dựng nhãn rủi ro có độ tin cậy cao hơn so với dữ liệu gốc, hệ thống tạo ra đặc trưng *Computed Risk* dựa trên tổ hợp nhiều yếu tố nguy hiểm.

Các thành phần bao gồm: *mức độ gần vật cản*, *tốc độ phương tiện*, *mật độ giao thông*, *số lượng vật cản* và *mức độ phanh khẩn cấp*.

Giá trị rủi ro tổng hợp được tính bằng mô hình trọng số:

$$Computed\ Risk = w_1R_1 + w_2R_2 + w_3R_3 + w_4R_4 + w_5R_5$$

Trong đó:

- R_i là các thành phần rủi ro chuẩn hóa.
- w_i là trọng số phản ánh mức độ quan trọng của từng yếu tố.

Đặc trưng này đóng vai trò làm mục tiêu học cho mô hình AI, hỗ trợ Bayesian Risk Estimation và tăng khả năng đánh giá nguy hiểm theo thời gian thực.

5 Các thuật toán sử dụng

- **Behavior Prediction** – Dự đoán hành vi giao thông của phương tiện.
- **Risk Probability Prediction** – Dự đoán xác suất và mức độ rủi ro của tình huống giao thông.
- **A* Search** – Tìm kiếm quỹ đạo tối ưu

5.1 Tiền xử lý dữ liệu

Trước khi huấn luyện mô hình, dữ liệu được chuẩn hóa bằng thuật toán **StandardScaler** nhằm đưa các đặc trưng về cùng miền giá trị. Với đặc trưng đầu vào x , giá trị chuẩn hóa được tính theo:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- μ : giá trị trung bình của đặc trưng.
- σ : độ lệch chuẩn.

Ngoài ra, các nhãn hành vi giao thông được mã hóa bằng **LabelEncoder** để chuyển dữ liệu dạng chuỗi sang dạng số phục vụ cho mô hình phân loại.

5.2 Behavior Prediction – Dự đoán hành vi

Mô-đun này có nhiệm vụ dự đoán hành vi của phương tiện trong môi trường giao thông như: *Đi thẳng, Rẽ trái, Rẽ phải, Phanh gấp, Chuyển làn*

Đây là bài toán **Classification** nên hệ thống sử dụng nhiều mô hình phân loại khác nhau nhằm tăng độ chính xác và khả năng tổng quát hóa.

5.2.1 Gaussian Naive Bayes

Thuật toán **Gaussian Naive Bayes** được sử dụng như mô hình baseline cho bài toán dự đoán hành vi.

Mô hình giả định rằng các đặc trưng đầu vào độc lập có điều kiện với nhau và tuân theo phân phối Gaussian:

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

Xác suất hậu nghiệm được tính bằng định lý Bayes:

$$P(y|X) \propto P(y) \prod_{i=1}^n P(x_i|y)$$

Ưu điểm của Gaussian Naive Bayes:

- Tốc độ huấn luyện nhanh.
- Phù hợp với dữ liệu nhiều chiều.
- Hoạt động hiệu quả trong thời gian thực.

Trong hệ thống, tham số `var_smoothing` được tối ưu bằng **GridSearchCV**.

5.2.2 Random Forest Classifier

Để tăng tính ổn định và giảm overfitting, hệ thống sử dụng **Random Forest Classifier**. Random Forest là mô hình Ensemble Learning dựa trên nhiều cây quyết định độc lập:

$$\hat{y} = \text{majority vote}(T_1, T_2, \dots, T_n)$$

Trong đó:

- T_i : cây quyết định thứ i .
- Kết quả cuối cùng được xác định bằng bỏ phiếu đa số.

Các hyperparameter được tối ưu gồm: `n_estimators`, `max_depth`, `min_samples_split`, `class_weight`
Hệ thống sử dụng:

$$\text{class_weight} = \text{balanced}$$

để xử lý hiện tượng mất cân bằng dữ liệu giữa các nhóm hành vi giao thông.

5.2.3 XGBoost Classification

Nhằm tăng hiệu suất dự đoán hành vi phi tuyến, hệ thống tích hợp **XGBoost Classifier**. Mô hình hoạt động theo cơ chế Gradient Boosting:

$$F_t(x) = F_{t-1}(x) + \eta h_t(x)$$

Trong đó:

- $F_t(x)$: mô hình tại vòng lặp thứ t .
- $h_t(x)$: cây quyết định mới được thêm vào.
- η : learning rate.

Mô hình sử dụng:

- 200 cây quyết định.
- Hàm mất mát `mlogloss`.

Nếu XGBoost đạt độ chính xác cao hơn Random Forest thì hệ thống sẽ tự động chọn XGBoost làm mô hình chính cho Behavior Prediction.

5.3 Risk Probability Prediction – Dự đoán xác suất rủi ro

Mô-đun này có nhiệm vụ dự đoán xác suất xảy ra nguy hiểm hoặc mức độ rủi ro của tình huống giao thông dựa trên trạng thái môi trường hiện tại.

Đây là bài toán **Regression**, trong đó đầu ra là một giá trị liên tục biểu diễn mức độ nguy hiểm của tình huống.

5.3.1 Decision Tree Regressor

Hệ thống sử dụng **Decision Tree Regressor** để mô hình hóa mối quan hệ phi tuyến giữa các đặc trưng giao thông và chỉ số rủi ro.

Mô hình hoạt động bằng cách phân chia không gian đặc trưng thành nhiều vùng con nhằm giảm sai số hồi quy:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Các siêu tham số được tối ưu gồm: `max_depth`, `min_samples_split`, `min_samples_leaf`
Hiệu suất mô hình được đánh giá bằng hệ số:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

5.3.2 XGBoost Regression

Để tăng khả năng dự đoán các quan hệ rủi ro phức tạp, hệ thống tích hợp thêm **XGBoost Regressor**.

Mô hình sử dụng cơ chế Gradient Boosting nhằm giảm sai số hồi quy qua nhiều vòng lặp liên tiếp.

Nếu giá trị R^2 của XGBoost cao hơn Decision Tree Regressor thì hệ thống sẽ tự động chọn XGBoost làm mô hình chính cho bài toán Risk Probability Prediction.


5.4 Path Planning - Mô hình tìm kiếm quỹ đạo

Sau khi đánh giá trạng thái và rủi ro, hệ thống sử dụng thuật toán A* để tìm quỹ đạo tối ưu:


$$f(n) = g(n) + h(n)$$

Trong đó, $g(n)$ là chi phí thực tế, $h(n)$ là heuristic ước lượng tới đích và $f(n)$ là tổng chi phí đánh giá.

Thuật toán A* giúp tối ưu đường đi, giảm chi phí tính toán và đáp ứng yêu cầu thời gian thực.



Hình 3: Quỹ đạo A* trong kịch bản Chuyển làn (Lane Change)



Hình 4: Quỹ đạo A* trong kịch bản Vượt xe (Overtake)

5.5 Cơ chế lựa chọn mô hình

Sau khi huấn luyện, hệ thống tự động lựa chọn mô hình có hiệu suất tốt nhất:

$$Model_{final} = \arg \max(ModelPerformance)$$

Đối với bài toán Behavior Prediction:

$$XGBoost > RandomForest > NaiveBayes$$

Đối với bài toán Risk Probability Prediction:

$$XGBoost > DecisionTree$$

Cơ chế này giúp NeuroDrive-K duy trì hiệu suất tối ưu trong nhiều điều kiện giao thông khác nhau.

6 Thực nghiệm

Các thực nghiệm được thực hiện nhằm đánh giá toàn diện hiệu quả của hệ thống NeuroDrive-K trên ba thành phần chính:

- Khả năng dự đoán hành vi giao thông bằng Machine Learning.
- Khả năng dự đoán mức độ rủi ro của môi trường giao thông.
- Hiệu suất lập kế hoạch quỹ đạo của thuật toán A* trong môi trường động.

Hệ thống được kiểm thử trên nhiều kịch bản giao thông khác nhau bao gồm môi trường đô thị, đường cao tốc và điều kiện thời tiết sương mù nhằm đánh giá tính ổn định và khả năng thích nghi của kiến trúc Hybrid AI.

6.1 Đánh giá mô hình Behavior Prediction

Bài toán Behavior Prediction được xây dựng dưới dạng bài toán phân lớp nhằm dự đoán hành vi giao thông của các phương tiện xung quanh.

Các chỉ số đánh giá bao gồm:

- Accuracy – độ chính xác tổng thể.
- Precision – khả năng dự đoán chính xác các hành vi nguy hiểm.
- Recall – khả năng phát hiện đầy đủ các tình huống rủi ro.
- F1-Score – trung bình điều hòa giữa Precision và Recall.

Kết quả thực nghiệm được trình bày trong Bảng 2.

Model	Accuracy	Precision	Recall	F1-Score
Naive Bayes	67.9%	58.9%	66.0%	53.3%
Random Forest	76.0%	71.4%	75.7%	67.7%
XGBoost	78.1%	72.1%	69.3%	66.5%

Bảng 2: Kết quả đánh giá Behavior Prediction

Kết quả cho thấy XGBoost đạt Accuracy cao nhất với 78.1%, cho thấy khả năng học tốt các quan hệ phi tuyến phức tạp trong dữ liệu giao thông. Trong khi đó, Random Forest đạt Recall cao hơn với 75.7%, thể hiện khả năng phát hiện các tình huống nguy hiểm hiệu quả hơn.

Naive Bayes cho kết quả thấp hơn do giả định độc lập giữa các đặc trưng chưa phù hợp với môi trường giao thông động, nơi các yếu tố như vận tốc, khoảng cách và hướng di chuyển có mối quan hệ chặt chẽ với nhau.

6.2 Đánh giá mô hình Risk Prediction

Bài toán Risk Prediction được xây dựng dưới dạng bài toán hồi quy nhằm ước lượng xác suất hoặc mức độ nguy hiểm của tình huống giao thông hiện tại.

Các chỉ số đánh giá bao gồm:

- R^2 Score – mức độ giải thích biến thiên dữ liệu.
- MAE (Mean Absolute Error) – sai số tuyệt đối trung bình.
- MSE (Mean Squared Error) – sai số bình phương trung bình.

Kết quả thực nghiệm được trình bày trong Bảng 3.

Model	R2 Score	MAE	MSE
Decision Tree	0.9549	0.0226	0.0009
XGBoost	0.9946	0.0078	0.0001

Bảng 3: Kết quả đánh giá Risk Prediction

Kết quả cho thấy XGBoost vượt trội hơn so với Decision Tree trong bài toán dự đoán rủi ro. Mô hình đạt $R^2 = 0.9946$, đồng thời MAE và MSE đều rất thấp, cho thấy khả năng dự đoán mức độ nguy hiểm gần sát với giá trị thực tế.

Điều này chứng minh rằng XGBoost phù hợp với bài toán Risk Prediction do khả năng tối ưu hóa gradient boosting và xử lý tốt dữ liệu phi tuyến có độ phức tạp cao.

6.3 Hiệu suất thuật toán A*

Thuật toán A* được sử dụng để tìm quỹ đạo tối ưu trong không gian trạng thái động. Các tiêu chí đánh giá bao gồm:

- Thời gian tìm đường.
- Số lượng trạng thái đã duyệt.
- Tỷ lệ tìm được quỹ đạo hợp lệ.

Kết quả thực nghiệm được trình bày trong Bảng 4.

Scenario	Time(ms)	States	Success Rate
Urban Traffic	33.4	7252	90%
Highway	29.7	6462	100%
Foggy Weather	24.2	5329	100%

Bảng 4: Hiệu suất thuật toán A*

Trong môi trường đô thị, số lượng trạng thái cần duyệt lớn hơn do mật độ phương tiện và vật cản động cao, dẫn đến thời gian tìm đường tăng lên. Tuy nhiên, thuật toán vẫn duy trì thời gian xử lý dưới $35ms$, đáp ứng yêu cầu thời gian thực của hệ thống xe tự hành.

Ở môi trường đường cao tốc và điều kiện sương mù, thuật toán đạt tỷ lệ thành công 100%, cho thấy heuristic và hàm chi phí được thiết kế hiệu quả trong không gian trạng thái động.

6.4 Đánh giá an toàn và ổn định hệ thống

Để đánh giá mức độ an toàn của hệ thống, các chỉ số sau được sử dụng:

- Collision Rate – tỷ lệ va chạm.

- Average Displacement Error (ADE) – sai lệch quỹ đạo trung bình.
- Lane Keeping Stability – độ ổn định khi giữ làn.

Kết quả thực nghiệm được trình bày trong Bảng 5.

Scenario	Collision Rate	ADE	Stability
Normal Weather	35.3%	0.26	Medium
Foggy Weather	39.9%	0.24	Medium

Bảng 5: So sánh các kịch bản thử nghiệm

Kết quả cho thấy điều kiện thời tiết ảnh hưởng đáng kể đến khả năng điều hướng an toàn của hệ thống. Trong môi trường sương mù, tỷ lệ va chạm tăng lên do khả năng quan sát và nhận diện môi trường bị hạn chế.

Tuy nhiên, chỉ số ADE vẫn duy trì ở mức thấp, chứng tỏ hệ thống vẫn có khả năng giữ quỹ đạo ổn định và thực hiện điều hướng tương đối chính xác ngay cả trong điều kiện bất lợi.

7 Phân tích kết quả

Kết quả thực nghiệm cho thấy kiến trúc Hybrid AI trong NeuroDrive-K có khả năng kết hợp hiệu quả giữa Machine Learning, Bayesian Inference và thuật toán tìm kiếm A^* nhằm giải quyết bài toán điều hướng xe tự hành trong môi trường động.

Đối với bài toán Behavior Prediction, các mô hình Ensemble Learning như Random Forest và XGBoost cho hiệu suất vượt trội so với Naive Bayes nhờ khả năng mô hình hóa các quan hệ phi tuyến giữa các đặc trưng giao thông.

XGBoost đạt Accuracy cao nhất, cho thấy khả năng tổng quát hóa tốt trên dữ liệu phức tạp. Trong khi đó, Random Forest đạt Recall cao hơn, phù hợp với các tình huống yêu cầu phát hiện tối đa các nguy cơ tiềm ẩn nhằm tăng độ an toàn cho hệ thống.

Trong bài toán Risk Prediction, XGBoost tiếp tục cho kết quả tốt nhất với $R^2 = 0.9946$ cùng sai số MAE và MSE rất thấp. Điều này cho thấy mô hình có khả năng dự đoán mức độ nguy hiểm với độ chính xác rất cao, góp phần cải thiện chất lượng ra quyết định trong môi trường giao thông động.

Đối với bài toán lập kế hoạch quỹ đạo, thuật toán A^* duy trì thời gian xử lý thấp dưới 35 ms trong tất cả các kịch bản thử nghiệm. Điều này chứng minh hệ thống đáp ứng được yêu cầu thời gian thực của xe tự hành.

Ngoài ra, tỷ lệ tìm được quỹ đạo hợp lệ luôn đạt từ 90% trở lên, cho thấy heuristic và cơ chế đánh giá chi phí hoạt động hiệu quả ngay cả trong môi trường có nhiều trạng thái và vật cản động.

Kết quả đánh giá an toàn cho thấy hệ thống vẫn duy trì được độ ổn định tương đối tốt trong điều kiện thời tiết bất lợi. Mặc dù Collision Rate tăng trong môi trường sương mù do mức độ bất định cao hơn, chỉ số ADE vẫn thấp, chứng tỏ cơ chế dự đoán hành vi và tối ưu quỹ đạo vẫn hoạt động ổn định.

Tổng thể, các kết quả thực nghiệm xác nhận rằng kiến trúc Hybrid AI giúp cải thiện khả năng dự đoán, tăng độ an toàn và duy trì hiệu suất ổn định trong nhiều tình huống giao thông khác nhau. Hệ thống NeuroDrive-K cho thấy tiềm năng ứng dụng trong các bài toán điều hướng xe tự hành thời gian thực.

8 Kết luận

Đề tài NeuroDrive-K đã xây dựng thành công một framework Hybrid AI cho bài toán xe tự hành bằng cách kết hợp nhiều thành phần trí tuệ nhân tạo khác nhau gồm Machine Learning, Bayesian Probability, Rule-based System và thuật toán tìm kiếm heuristic A*.

Kiến trúc hệ thống cho phép mô hình vừa học được các đặc trưng phi tuyến phức tạp từ dữ liệu giao thông, vừa duy trì khả năng suy luận logic và kiểm soát an toàn trong môi trường động. Thông qua cơ chế kết hợp giữa dự đoán hành vi, đánh giá rủi ro Bayesian và lập kế hoạch quỹ đạo tối ưu, hệ thống có thể đưa ra các quyết định điều hướng phù hợp theo thời gian thực.

Kết quả thực nghiệm cho thấy các mô hình Ensemble Learning, đặc biệt là XGBoost, đạt hiệu suất cao trong cả hai bài toán Behavior Prediction và Risk Prediction. Trong đó:

- XGBoost đạt Accuracy cao nhất trong dự đoán hành vi giao thông.
- XGBoost Regressor đạt $R^2 = 0.9946$ trong bài toán dự đoán rủi ro.

Điều này chứng minh khả năng mô hình hóa hiệu quả các quan hệ phi tuyến và dữ liệu giao thông phức tạp của hệ thống.

Đối với bài toán lập kế hoạch quỹ đạo, thuật toán A* kết hợp Cost Map Fusion đã duy trì thời gian xử lý thấp và tỷ lệ tìm được quỹ đạo hợp lệ cao trong nhiều kịch bản giao thông khác nhau. Hệ thống vẫn đảm bảo khả năng điều hướng ổn định ngay cả trong điều kiện bất lợi như sương mù hoặc môi trường có mật độ giao thông cao.

Bên cạnh đó, việc tích hợp Bayesian Inference và Rule-based Safety System giúp NeuroDrive-K tăng khả năng xử lý dữ liệu bất định, phát hiện nguy cơ sớm và đảm bảo các quyết định luôn tuân thủ các ràng buộc an toàn giao thông. Đây là ưu điểm quan trọng của kiến trúc Hybrid AI so với các hệ thống chỉ dựa hoàn toàn vào học máy thuần túy.

Tổng thể, các kết quả đạt được cho thấy NeuroDrive-K có tiềm năng ứng dụng trong các hệ thống hỗ trợ lái xe thông minh và xe tự hành thời gian thực. Đồng thời, framework này cũng tạo nền tảng cho các hướng phát triển nâng cao trong tương lai như:

- Deep Reinforcement Learning cho điều hướng thích nghi.
- Multi-Agent Autonomous Driving.
- Real-time Sensor Fusion với camera, LiDAR và radar.
- V2X Communication trong hệ thống giao thông thông minh.
- End-to-End Hybrid Autonomous Driving Architecture.

Qua đó, đề tài góp phần minh họa hiệu quả của việc kết hợp nhiều phương pháp AI trong giải quyết bài toán xe tự hành, hướng tới các hệ thống điều hướng an toàn, ổn định và có khả năng mở rộng trong thực tế.